

Vorlesung

Theoretische Informatik


(08 Eigenschaften Kontextfreier Sprachen, GNF)

Alois Heinz
Hochschule Heilbronn,
Max-Planck-Str. 39, 74081 Heilbronn
`heinz@hs-heilbronn.de`

28. April/05. Juni 2026

Ableitungsbäume für Kontextfreie Grammatiken (1)



- Für die Erzeugung von $w \in L(G)$ mit $G = (\Sigma, N, P, S)$ gibt es oft viele **verschiedene Folgen** von Ableitungsschritten
- Sei etwa $w = aabbaa$ und $P = (S \rightarrow aAS \mid a, A \rightarrow SbA \mid SS \mid ba)$.
- In einer **Linksableitung** wird immer das linkeste Nichtterminal ersetzt:
 $\underline{S} \Rightarrow a\underline{A}S \Rightarrow a\underline{S}bAS \Rightarrow aab\underline{A}S \Rightarrow aabba\underline{S} \Rightarrow aabbaa$
- In einer **Rechtsableitung** wird immer das rechteste Nichtterminal ersetzt:
 $\underline{S} \Rightarrow aA\underline{S} \Rightarrow aAa \Rightarrow aSb\underline{A}a \Rightarrow aSbbaa \Rightarrow aabbaa$
- **Ableitungsbäume** bieten eine Veranschaulichung der Ableitungsschritte einer kontextfreien Grammatik. Bsp. für w und G :



Ableitungsbäume für Kontextfreie Grammatiken (2)

T_G heißt **Ableitungsbaum** über $G = (\Sigma, N, P, S)$, falls gilt:

1. T_G ist ein Knoten-markierter Wurzelbaum
 2. Jeder innere Knoten ist mit einem Zeichen aus N markiert, die Wurzel mit S
 3. Jedes Blatt ist mit einem Symbol aus $N \cup \Sigma \cup \{\epsilon\}$ markiert
 4. Ist ein innerer Knoten mit $A \in N$ markiert und die Kinder von links nach rechts mit $X_1, \dots, X_k$, dann muss gelten: $A \rightarrow X_1 \dots X_k \in P$
- Sei jetzt $w = abc$ und $P = (S \rightarrow aB \mid Ac, A \rightarrow ab, B \rightarrow bc)$.
 - Zwei **Ableitungsbäume** von w sind verschieden :




Mehrdeutigkeit

Eine kontextfreie Grammatik G heißt **mehrdeutig**, wenn es für mindestens ein Wort $w \in L(G)$ verschiedene Ableitungsbäume (Linksableitungen | Rechtsableitungen) gibt.

Eine kontextfreie Sprache L heißt **inhärent mehrdeutig**, wenn jede Grammatik G mit $L = L(G)$ mehrdeutig ist.

Bsp: $G_{Arith} = (\{a, (,), +, -, *, /\}, \{E, O\}, P, E)$ mit
 $P = \{E \rightarrow a \mid EOE \mid (E), O \rightarrow + \mid - \mid * \mid /\}$ ist mehrdeutig:



Bsp: Die Sprache $L = \{a^i b^j c^k \mid i = j \text{ oder } j = k\}$ ist inhärent mehrdeutig.

Das Pumping-Lemma für Kontextfreie Sprachen (1)

Ziel: Test dafür, dass eine Sprache **nicht kontextfrei** ist.

Angabe einer **notwendigen** (nicht hinreichenden) Eigenschaft kontextfreier Sprachen.

Satz. (Pumping-Lemma für kontextfreie Sprachen)

Sei L eine kontextfreie Sprache. Dann gibt es eine Zahl $n \in \mathbb{N}$, so dass sich alle Wörter $z \in L$ mit $|z| \geq n$ zerlegen lassen in $z = uvwxy$, und es gilt:

1. $|vx| \geq 1$
2. $|vwx| \leq n$
3. $uv^iwx^iy \in L$ für alle $i \in \mathbb{N}$


Ab einer gewissen Größe eines Wortes einer kontextfreien Sprache können zwei Teile darin beliebig oft wiederholt werden, und das Ergebnis gehört ebenfalls zur Sprache.

Das Pumping-Lemma für Kontextfreie Sprachen (2)

Beweis. (Skizze)

Sei $G = (\Sigma, N, P, S)$ in CNF mit $L(G) = L$ und $|N| = m$. Wähle $n := 2^m$.

- Der Ableitungsbaum für $z \in L$ mit $|z| \geq n$ ist binär, außer in der letzten Stufe.
- Der Binärbaum hat $\geq 2^m$ Blätter, daher mindestens einen Pfad mit $\geq m + 1$ Knoten, markiert mit Elementen aus N .
- Es gibt einen Pfad (Wurzel-Blatt), auf dem ein $A \in N$ mehrfach vorkommt.



- Das unterste A : $A \Rightarrow^* w$, das zweit-unterste A : $A \Rightarrow^* vAx \Rightarrow^* vwx$
- Wegen G in CNF folgt: $|vx| \geq 1$
- Ab dem zweit-untersten A braucht es bis zu jedem $a \in \Sigma$ höchstens m binäre Ableitungsschritte, somit ist $|vwx| \leq n$
- Ableitungen $A \Rightarrow^* vAx$ können beliebig oft ausgeführt werden. $\square$

Nicht Kontextfreie Sprachen

Satz. Die Sprache $L = \{a^k b^k c^k \mid k \geq 0\}$ ist nicht kontextfrei.

Widerspruchsbeweis.

Angenommen, L ist kontextfrei. Dann gibt es $n \in \mathbb{N}$, so dass alle $z \in L$ mit $|z| \geq n$ Bedingungen 1.-3. des Pumping-Lemmas erfüllen.

- Wähle $z = a^n b^n c^n = uvwxy$, also $|z| = 3n > n$.
- Wegen Bedingung 2. ist $|vwx| \leq n$
- Somit kann *nicht* gelten: $a \in v$ *und* $c \in x$
- vx enthält vielleicht nur b , ansonsten entweder a oder c , aber nicht von beiden
- uwy ist sicher nicht mehr von der Form $a^k b^k c^k$ $\square$

Abschlusseigenschaften kontextfreier Sprachen (1)

Satz. Für jedes Alphabet Σ gilt: kfS_Σ ist abgeschlossen unter:

1. Vereinigung 2. Konkatenation 3. Kleene-Stern-Produkt 4. Spiegelung

Beweis. Seien G, G_1, G_2 kontextfreie Grammatiken für die Sprachen L, L_1, L_2 mit disjunkten N, N_1, N_2 :

1. Eine Grammatik $G_\cup$ für $L_1 \cup L_2$ benötigt als Startsymbol ein weiteres Nichtterminal $S_\cup$ und zwei zusätzliche Regeln: $S_\cup \rightarrow S_1 \mid S_2$
2. Eine Grammatik $G_\circ$ für $L_1 \circ L_2$ benötigt als Startsymbol ein weiteres Nichtterminal $S_\circ$ und eine zusätzliche Regel: $S_\circ \rightarrow S_1 S_2$
3. Eine Grammatik G_* für L^* benötigt als Startsymbol ein weiteres Nichtterminal S_* und zwei zusätzliche Regeln: $S_* \rightarrow \epsilon \mid S S_*$
4. Die Grammatik G für L sei in CNF. Daraus entsteht eine Grammatik $\tilde{G}$ für die Spiegelschrift $\tilde{L}$ durch Spiegeln aller Regeln der Form $A \rightarrow BC$ in $A \rightarrow CB$. $\square$

Abschlusseigenschaften kontextfreier Sprachen (2)

Satz. kfS_{Σ} ist nicht abgeschlossen unter:

1. Durchschnitt 2. Komplement 3. Differenz

Beweis.

1. Wir betrachten die beiden kontextfreien Sprachen

$$L_1 = \{a^k b^k c^{\ell} \mid k, \ell \geq 0\} \quad \text{und} \quad L_2 = \{a^i b^j c^j \mid i, j \geq 0\}$$

sowie deren Durchschnitt

$$L_1 \cap L_2 = \{a^m b^m c^m \mid m \geq 0\}$$

das mit Hilfe des Pumping-Lemmas als nicht kontextfrei erkannt wurde.

2. Da kfS_{Σ} unter Vereinigung abgeschlossen ist, würde aus der Abgeschlossenheit unter Komplement die Abgeschlossenheit unter Durchschnitt folgen mit den De Morganschen Regeln:

$$L_1 \cap L_2 = \overline{\overline{L_1} \cup \overline{L_2}}$$

Greibach-Normalform (1)

Eine kontextfreie Grammatik $G = (\Sigma, N, P, S)$ ist in Greibach-Normalform oder GNF, falls gilt:

$$P \subseteq N \times (\Sigma \circ N^*)$$

Kontextfreie Regeln in Greibach-Normalform haben die Form

$$A \rightarrow aB_1 \dots B_m, m \geq 0$$

mit $A, B_i \in N$ und $a \in \Sigma$. (Für $m \leq 1$ ist es eine Typ-3 Regel.)

Satz. Zu jeder kontextfreien Grammatik $G = (\Sigma, N, P, S)$ mit $\epsilon \notin L(G)$ existiert eine äquivalente Grammatik in G' Greibach-Normalform.

Betrachte Grammatik:

$G = (\{a, b\}, \{S, A, B\}, P, S)$ mit

$P = \{S \rightarrow aBS \mid bAS \mid \epsilon, A \rightarrow a \mid bAA, B \rightarrow b \mid aBB\}$

Was ist $L(G)$? Was ist das Besondere an G ?

Greibach-Normalform (2)

Beweis zum GNF-Satz. (3 Schritte): Sei G in CNF mit $N = \{A_1, \dots, A_m\}$

0. **Vorüberlegung:** Hat G die A -Regeln $A \rightarrow A\alpha_1 \mid \dots \mid A\alpha_k \mid \beta_1 \mid \dots \mid \beta_\ell$,
so lassen sich damit genau die Wörter in $(\beta_1 \mid \dots \mid \beta_\ell)(\alpha_1 \mid \dots \mid \alpha_k)^*$ ableiten.
Dafür können auch die Regeln mit einem neuen Symbol $B \in N$ verwendet werden:

$$\begin{aligned} A &\rightarrow \beta_1 \mid \dots \mid \beta_\ell \mid \beta_1 B \mid \dots \mid \beta_\ell B, \\ B &\rightarrow \alpha_1 \mid \dots \mid \alpha_k \mid \alpha_1 B \mid \dots \mid \alpha_k B. \end{aligned}$$

Damit kann **Linksrekursion** durch **Rechtsrekursion** ersetzt werden.

1. **Ersetzen** von Regeln, so dass aus $A_i \rightarrow A_j \alpha \in P$ folgt $i < j$:
- ```
for (i from 1 to m) {
 for (j from 1 to i - 1)
 for (all $A_i \rightarrow A_j \alpha \in P$) {
 Seien $A_j \rightarrow \beta_1 \mid \dots \mid \beta_n$ alle A_j -Regeln;
 $P := P \cup \{A_i \rightarrow \beta_1 \alpha \mid \dots \mid \beta_n \alpha\}$;
 $P := P \setminus \{A_i \rightarrow A_j \alpha\}$; }
 for (all $r = A_i \rightarrow A_i \alpha \in P$)
 Ersetze r durch neue Regeln mit neuem Symbol $B_i \in N$ gemäß 0
}
```

## Greibach-Normalform (3)

2. Die rechte Seite jeder  $A_m$ -Regel hat nun links ein  $a \in \Sigma$ .

Dies wird ebenfalls erreicht für alle anderen  $A_i$ -Regeln mit  $i \in \{1, \dots, m-1\}$ :

```
for (i from $m-1$ downto 1)
 for (all $A_i \rightarrow A_j \alpha \in P, j > i$) {
 Seien $A_j \rightarrow \beta_1 \mid \dots \mid \beta_n$ alle A_j -Regeln;
 $P := P \cup \{A_i \rightarrow \beta_1 \alpha \mid \dots \mid \beta_n \alpha\}$;
 $P := P \setminus \{A_i \rightarrow A_j \alpha\}$;
 }
```

3. Entfernen der störenden  $B_i$ -Regeln:

```
for (all $B_i \rightarrow A_j \alpha \in P$) {
 Seien $A_j \rightarrow \beta_1 \mid \dots \mid \beta_n$ alle A_j -Regeln;
 $P := P \cup \{B_i \rightarrow \beta_1 \alpha \mid \dots \mid \beta_n \alpha\}$;
 $P := P \setminus \{B_i \rightarrow A_j \alpha\}$;
}
```

Die veränderte Grammatik  $G'$  ist nun in GNF und äquivalent zu  $G$ .  $\square$